

텍스트마이닝

: 기초 분석 (빈도분석 / TF-IDF)

강사 : 배현진

본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.

텍스트 분석하기

텍스트마이닝이란?

비정형 데이터인 텍스트부터 인사이트 추출을 위해 데이터를 정제하고 범주화
여기서 정제와 범주화는 **텍스트의 패턴 및 특징**을 분석하는 것

- ◆ 빈도분석
- ◆ TF-IDF



텍스트 수집

크롤링 / 스크래핑



텍스트 정제

정규표현식,
텍스트 전처리...



텍스트 마이닝

빈도분석,
연관어분석, 토픽모델링...



인사이트 도출

데이터 시각화

빈도 분석 : Count & WordCloud & squarify

◆ 데이터 정제하기

1) 분석할 텍스트 정의하기

```
1 text = '나머지 두 번은 모두 국내에서 확진됐다. 오미크론 대유행이 한창이던 3월 직장예 음성확인서를 제출하려고 검사를 받았다가 양성인 양성이었다. 지난달에는 해외 출장을 위해 검사를 받았다가 또 양성인 양성이 나왔다. 병관리청 중앙방역대책본부(방대본)는 8일 0시 기준 신규 확진자가 5만5292명(국내발생 5만4810명, 해외유입 482명)이라고 밝혔다. 1주 전 월요일 확진자(4만4654명)에 견줘 약 1.24배 많은 규모다. 지난 2일부터 최근 일주일간 확진자 발생 추이는 11만1758명→11만9889명→10만7869명→11만2901명→11만666명→10만5507명→5만5292명이다. 주간(8월2일~8일) 하루 평균 확진자는 약 10만3412명으로, 10만명대를 넘었다. 누적 확진자는 2054만4420명이다. 위중증 환자는 하루 사이 27명 늘어 324명으로 파악됐다. 최근 1주간 위중증 환자 발생 추이는 282
```

2) 형태소 분석기를 통해 텍스트 정제하기 (특정 품사 추출 / 불용어 제거)

```
1 result = okt.nouns(text)

['나머지',
 '두',
 '번',
 '모두',
 '국내',
 '확진',
 '됐다',
 '오미크론',
 '대유행',
 '한창',
 '이던',
 '3월',
 '직장',
 '음성',
 '확인',
 '서',
 '제출',
 '하',
 '려',
 '고',
 '검',
 '사',
 '를',
 '받',
 '았',
 '다',
 '가',
 '양',
 '성',
 '인',
 '양',
 '성',
 '이',
 '었',
 '다',
 '지',
 '난',
 '달',
 '에',
 '는',
 '해',
 '외',
 '출',
 '장',
 '을',
 '위',
 '해',
 '검',
 '사',
 '를',
 '받',
 '았',
 '다',
 '가',
 '또',
 '양',
 '성',
 '인',
 '양',
 '성',
 '이',
 '나',
 '왔',
 '다',
 '병',
 '관',
 '리',
 '청',
 '중',
 '央',
 '방',
 '역',
 '대',
 '책',
 '본',
 '부',
 '는',
 '8',
 '일',
 '0',
 '시',
 '기',
 '준',
 '신',
 '규',
 '확',
 '진',
 '자',
 '가',
 '5',
 '만',
 '5',
 '2',
 '9',
 '2',
 '명',
 '국',
 '내',
 '발',
 '생',
 '5',
 '만',
 '4',
 '8',
 '1',
 '0',
 '명',
 '해',
 '외',
 '유',
 '입',
 '4',
 '8',
 '2',
 '명',
 '이',
 '라',
 '고',
 '발',
 '표',
 '했',
 '다',
 '1',
 '주',
 '전',
 '월',
 '요',
 '일',
 '확',
 '진',
 '자',
 '4',
 '만',
 '4',
 '6',
 '5',
 '4',
 '명',
 '에',
 '견',
 '줘',
 '약',
 '1',
 '2',
 '4',
 '배',
 ' 많',
 '은',
 '구',
 '모',
 '다',
 '지',
 '난',
 '2',
 '일',
 '부',
 '터',
 '최',
 '근',
 '일',
 '주',
 '일',
 '간',
 '확',
 '진',
 '자',
 '발',
 '생',
 '추',
 '이',
 '는',
 '1',
 '1',
 '만',
 '1',
 '7',
 '5',
 '8',
 '명',
 '→',
 '1',
 '1',
 '만',
 '9',
 '8',
 '8',
 '9',
 '명',
 '→',
 '1',
 '0',
 '만',
 '7',
 '8',
 '6',
 '9',
 '명',
 '→',
 '1',
 '1',
 '만',
 '2',
 '9',
 '0',
 '1',
 '명',
 '→',
 '1',
 '1',
 '만',
 '6',
 '6',
 '6',
 '명',
 '→',
 '1',
 '0',
 '만',
 '5',
 '5',
 '0',
 '7',
 '명',
 '→',
 '5',
 '만',
 '5',
 '2',
 '9',
 '2',
 '명',
 '이',
 '다',
 '주',
 '간',
 '8',
 '월',
 '2',
 '일',
 '~',
 '8',
 '일',
 '하',
 '루',
 '평',
 '균',
 '확',
 '진',
 '자',
 '는',
 '약',
 '1',
 '0',
 '만',
 '3',
 '4',
 '1',
 '2',
 '명',
 '으',
 '로',
 '1',
 '0',
 '만',
 '명',
 '대',
 '를',
 '넘',
 '었',
 '다',
 '누',
 '적',
 '확',
 '진',
 '자',
 '는',
 '2',
 '0',
 '5',
 '4',
 '만',
 '4',
 '4',
 '2',
 '0',
 '명',
 '이',
 '다',
 '위',
 '중',
 '증',
 '환',
 '자',
 '는',
 '하',
 '루',
 '사',
 '이',
 '2',
 '7',
 '명',
 '늘',
 '어',
 '3',
 '2',
 '4',
 '명',
 '으',
 '로',
 '파',
 '악',
 '됐',
 '다',
 '최',
 '근',
 '1',
 '주',
 '간',
 '위',
 '중',
 '증',
 '환',
 '자',
 '발',
 '생',
 '추',
 '이',
 '는',
 '2',
 '8',
 '2']
```

3) collections 라이브러리를 통해 추출된 워드 카운팅

```
1 from collections import Counter
2
3 # 갯수 세기
4 count = Counter(result)
5 count
```

```
Counter({'나머지': 1,
        '두': 1,
        '번': 1,
        '모두': 3,
        '국내': 2,
        '확진': 2,
        '오미크론': 2,
        '대유행': 1,
        '한창': 1,
        '직장': 1,
        '음성': 1,
        '확인': 1,
        '서': 1,
        '제출': 1,
        '하': 1,
        '려': 1,
        '고': 1,
        '검': 1,
        '사': 1,
        '를': 1,
        '받': 1,
        '았': 1,
        '다': 1,
        '가': 1,
        '양': 1,
        '성': 1,
        '인': 1,
        '양': 1,
        '성': 1,
        '이': 1,
        '었': 1,
        '다': 1,
        '지': 1,
        '난': 1,
        '달': 1,
        '에': 1,
        '는': 1,
        '해': 1,
        '외': 1,
        '출': 1,
        '장': 1,
        '을': 1,
        '위': 1,
        '해': 1,
        '검': 1,
        '사': 1,
        '를': 1,
        '받': 1,
        '았': 1,
        '다': 1,
        '가': 1,
        '또': 1,
        '양': 1,
        '성': 1,
        '인': 1,
        '양': 1,
        '성': 1,
        '이': 1,
        '나': 1,
        '왔': 1,
        '다': 1,
        '병': 1,
        '관': 1,
        '리': 1,
        '청': 1,
        '중': 1,
        '央': 1,
        '방': 1,
        '역': 1,
        '대': 1,
        '책': 1,
        '본': 1,
        '부': 1,
        '는': 1,
        '8': 1,
        '일': 1,
        '0': 1,
        '시': 1,
        '기': 1,
        '준': 1,
        '신': 1,
        '규': 1,
        '확': 1,
        '진': 1,
        '자': 1,
        '가': 1,
        '5': 1,
        '만': 1,
        '5': 1,
        '2': 1,
        '9': 1,
        '2': 1,
        '명': 1,
        '국': 1,
        '내': 1,
        '발': 1,
        '생': 1,
        '5': 1,
        '만': 1,
        '4': 1,
        '8': 1,
        '1': 1,
        '0': 1,
        '명': 1,
        '해': 1,
        '외': 1,
        '유': 1,
        '입': 1,
        '4': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '라': 1,
        '고': 1,
        '발': 1,
        '표': 1,
        '했': 1,
        '다': 1,
        '1': 1,
        '주': 1,
        '전': 1,
        '월': 1,
        '요': 1,
        '일': 1,
        '확': 1,
        '진': 1,
        '자': 1,
        '4': 1,
        '만': 1,
        '4': 1,
        '6': 1,
        '5': 1,
        '4': 1,
        '명': 1,
        '에': 1,
        '견': 1,
        '줘': 1,
        '약': 1,
        '1': 1,
        '2': 1,
        '4': 1,
        '배': 1,
        ' 많': 1,
        '은': 1,
        '구': 1,
        '모': 1,
        '다': 1,
        '지': 1,
        '난': 1,
        '2': 1,
        '일': 1,
        '부': 1,
        '터': 1,
        '최': 1,
        '근': 1,
        '일': 1,
        '주': 1,
        '일': 1,
        '간': 1,
        '확': 1,
        '진': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '1': 1,
        '1': 1,
        '만': 1,
        '1': 1,
        '7': 1,
        '5': 1,
        '8': 1,
        '명': 1,
        '→': 1,
        '1': 1,
        '1': 1,
        '만': 1,
        '9': 1,
        '8': 1,
        '8': 1,
        '9': 1,
        '명': 1,
        '→': 1,
        '1': 1,
        '0': 1,
        '만': 1,
        '7': 1,
        '8': 1,
        '6': 1,
        '9': 1,
        '명': 1,
        '→': 1,
        '1': 1,
        '1': 1,
        '만': 1,
        '2': 1,
        '9': 1,
        '0': 1,
        '1': 1,
        '명': 1,
        '→': 1,
        '1': 1,
        '1': 1,
        '만': 1,
        '6': 1,
        '6': 1,
        '6': 1,
        '명': 1,
        '→': 1,
        '1': 1,
        '0': 1,
        '만': 1,
        '5': 1,
        '5': 1,
        '0': 1,
        '7': 1,
        '명': 1,
        '→': 1,
        '5': 1,
        '만': 1,
        '5': 1,
        '2': 1,
        '9': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '주': 1,
        '간': 1,
        '8': 1,
        '월': 1,
        '2': 1,
        '일': 1,
        '~': 1,
        '8': 1,
        '일': 1,
        '하': 1,
        '루': 1,
        '평': 1,
        '균': 1,
        '확': 1,
        '진': 1,
        '자': 1,
        '는': 1,
        '약': 1,
        '1': 1,
        '0': 1,
        '만': 1,
        '3': 1,
        '4': 1,
        '1': 1,
        '2': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '1': 1,
        '0': 1,
        '만': 1,
        '명': 1,
        '대': 1,
        '를': 1,
        '넘': 1,
        '었': 1,
        '다': 1,
        '누': 1,
        '적': 1,
        '확': 1,
        '진': 1,
        '자': 1,
        '는': 1,
        '2': 1,
        '0': 1,
        '5': 1,
        '4': 1,
        '만': 1,
        '4': 1,
        '4': 1,
        '2': 1,
        '0': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '발': 1,
        '생': 1,
        '추': 1,
        '이': 1,
        '는': 1,
        '2': 1,
        '8': 1,
        '2': 1,
        '명': 1,
        '이': 1,
        '다': 1,
        '위': 1,
        '중': 1,
        '증': 1,
        '환': 1,
        '자': 1,
        '는': 1,
        '하': 1,
        '루': 1,
        '사': 1,
        '이': 1,
        '2': 1,
        '7': 1,
        '명': 1,
        '늘': 1,
        '어': 1,
        '3': 1,
        '2': 1,
        '4': 1,
        '명': 1,
        '으': 1,
        '로': 1,
        '파': 1,
        '악': 1,
        '됐': 1,
        '다': 1,
        '최': 1,
        '근': 1,
        '1': 1,
        '주': 1,
        '간
```

빈도 분석 : Count & WordCloud & squarify

◆ 데이터 세팅하고 시각화 실습하기

- 1) counter 에서 탑 15 뽑아보기
- 2) label 값 / size 값 - > 각각 리스트의 형태로
- 3) 트리맵의 컬러 설정
- 4) matplotlib 폰트 설정
- 5) 트리맵 그리기



[트리맵]

TF-IDF



TF-IDF

◆ TF-IDF란? (Term Frequency-Inverse Document Frequency)

- 빈도분석의 종류 (특정문서에서 특정 단어가 많이 등장하는 **어휘빈도** - 그 단어가 전체 문서에서 얼마나 드물게 등장하는지에 대한 **문서 역빈도**)
- 다른 말뭉치에서는 많이 등장하지 않지만, 하나의 말뭉치에서만 자주 등장하는 단어가 중요하다고 가정하는 기법
- 사실 단순히 빈도가 많다고 해서 해당 텍스트를 나타내는 주제 단어라고 보기는 어려움(나는, 이다, 하다...)
- 여기저기 나오는 단어보다 다른 문서들에 비해, 하나의 문서에서 유독 많이 등장하는 단어가 주제 단어일 가능성이 높다.



불용어 처리 해버리면 되지않아요?

빈도가 많은 단어가 의미가 없는 단어라고
단정하기 어려워요!



TF-IDF

◆ TF-IDF란? (Term Frequency-Inverse Document Frequency)

TF : 특정 단어의 빈도

DF : 특정 단어가 등장한 문서의 수

IDF : 단어의 역빈도

0~1의 값을 가지며 1에 가까울수록 굳

$tf(t, d)$

$tf(t, d)$ = 특정 말뭉치(d) 에서 단어 t 의 등장 빈도

$idf(t) = \log(\frac{n}{1+df(t)})$

$df(t)$ = 모든 말뭉치에서 단어 t 를 포함하고 있는 말뭉치의 수, n = 총 말뭉치의 수

$tf-idf(t) = tf(t) * idf(t)$

* **분모의 1 ?** : 특정 단어가 전체 문서에서 등장하지 않을 경우에 분모가 0이 되는 상황을 방지하기 위함

* **log를 취하는 이유?**

자주 쓰이지않는 희귀 단어랑 비교하면 자주 쓰이는 단어들은 수십 수백배 자주 등장, log를 씌워줌으로써 희귀단어에 엄청난 가중치가 부여되지않게 하기위함

TF-IDF

◆ 데이터 정제하기

1) 형태소 나누기

2) TF-IDF : TfidfVectorizer

3) 워드클라우드 or Squarify로 시각화

▶ 먼저 끝내신분은 일반 빈도 분석을 통해 출력한 결과와
TF-IDf 결과의 차이점도 확인해봅시다!