

텍스트마이닝

: Local Representation (Word Representation)


강사 : 배현진

본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.


Word Embeddings

Word Embeddings: 단어를 숫자로 치환하는 것

- 컴퓨터는 기본적으로 숫자밖에 인식하지 못한다.
- 인간의 언어는 숫자가 아니므로, 컴퓨터에게 인간의 언어를 인식시키기 위해서는 인간의 언어를 숫자로 바꿔야 한다.
- 관건은 어떻게 바꿀 것인가?



Word Embeddings의 종류




Local Representation : BoW

◆ Bag of Words (BoW)

하나의 단어를 하나의 **자연수**로 치환하는 것

횟수 표현 (Count-based Representation): 단어의 등장 빈도에 집중하는 기법



빨간 사과와 노란 바나나를 먹었다.
맛있는 사과는 빨가면 빨갈수록 맛있다.

사과 = 0, 맛있다 = 1, 바나나 = 2,
빨갈다 = 3, 노랗다 = 4, 먹다 = 5

(단어, 빈도) = (사과, 2), (맛있다, 2),
(바나나, 1), (빨갈다, 3), (노랗다, 1), (먹다, 1)

횟수 표현

3, 0, 4, 2, 5,
1, 0, 3, 3, 1

BoW

“빨갈다 = 3”이 가장 많이 등장한
것으로 보아 가장 중요하군!

빈도 분석




Local Representation : 원-핫 인코딩

◆ 원-핫 인코딩 (One-hot Encoding)

하나의 단어를 하나의 **이진수**로 치환하는 것

희소 표현 (Sparse Representation): 컴퓨터의 구동 방식에 집중하는 기법



빨간 사과와 노란 바나나를 먹었다.
맛있는 사과는 빨가면 빨갈수록 맛있다.

사과 = 0, 맛있다 = 1, 바나나 = 10,
빨갈다 = 11, 노랗다 = 100, 먹다 = 101

(단어, 빈도) = (사과, 2), (맛있다, 2),
(바나나, 1), (빨갈다, 3), (노랗다, 1), (먹다, 1)

횟수 표현

11, 0, 100, 10, 101,
1, 0, 11, 11, 1

원-핫

“빨갈다 = 11”이 가장 많이 등장한
것으로 보아 가장 중요하군!

빈도 분석




Local Representation : 원-핫 인코딩

Local Representation: 하나의 말뭉치를 하나의 숫자로 치환하는 것

- 희소 표현 (Sparse Representation): 컴퓨터의 구동 방식에 집중하는 기법
- 원-핫 인코딩 (One-hot Encoding): 하나의 단어를 하나의 **이진수**로 치환하는 것

	사과	맛있다	바나나	빨갳다	노랗다	먹다
Binary	1	1	1	1	1	1
Count-based	2	2	1	3	1	1



Local Representation

◆ 차원의 저주

Curse of Dimensionality: 차원이 많아지면 데이터의 설명성이 작아진다.

1. 차원이 뭐야?

데이터를 표현하는 특성(feature)들의 수

텍스트 마이닝은 문서를 벡터로, 표현 단어가 많아질 수록 차원이 커진다

2. 차원이 많아지면 왜 문제가 생겨?


특성이 많아지면 데이터가 너무 퍼져버려서 패턴을 찾기가 어렵다.

주로 데이터 포인트 간의 고유한 "근접성"이 감소하면서 발생


단어수가 너무 많으면 문서간의 거리가 멀어지고, 비슷한 문서를 찾는게 어려워진다.

이처럼, 차원이 무한히 커짐에 따라 점 A가 다른 데이터와 상호작용할 확률은 0에 수렴한다.

즉, 차원이 커지면 데이터의 의미는 그에 반비례하여 작아진다.



2차원 평면에서
어떤 점 A가 존재할 때,
점 A가 1cm의 거리 내에서
다른 데이터와 상호작용할 기하확률



한 면의 길이가 2cm인
3차원 공간에서
어떤 점 A가 존재할 때,
점 A가 1cm의 거리 내에서
다른 데이터와 상호작용할 기하확률

Local Representation

◆ 차원의 저주

Curse of Dimensionality: 차원이 많아지면 데이터의 설명성이 작아진다.

3. 어떻게 해결할까?

- * 의미없는 단어 줄이기,
- * 핵심단어만 남기기(TF-IDF...)
- * 차원 축소 기법 사용(PCA_주성분분석, LSA_잠재의미분석 ...)

차원을 축소할 때 가장 중요한 점은

데이터의 정보량을 **최대한 보존**해야 한다는 점!

PCA (Principal Component Analysis)

데이터의 중요한 패턴을 유지하면서 남기고 차원을 줄이는 방법

LSA (Latent Semantic Analysis)

동의어나 유사한 개념을 비슷한 값의 벡터로 변환
(텍스트에서만 적용)

***핵심단어만 남기는 방법과의 차이?**

TF-IDF와 같은 기법은 단어를 선택!

PCA/LSA는 정보를 압축!

비슷한 단어들을 묶어서 새로운 차원을 생성

데이터 변환을 통해 차원을 줄인다

Local Representation : n-gram

◆ 엔-그램 (n-gram)

연속된 **여러 개의 단어**를 하나의 자연수로 치환하는 것

통계적 표현 (Statistical Representation): 단어 간 동시 출현 확률에 집중하는 기법

빨간 사과와 노란 바나나를 먹었다.
맛있는 사과는 빨가면 빨갈수록 맛있다.

$n = 2$

빨갈다 사과 = 0

사과 노랳다 = 1

노랳다 바나나 = 2

바나나 먹다 = 3


먹다 맛있다 = 4

맛있다 사과 = 5

사과 빨갈다 = 6

빨갈다 빨갈다 = 7

빨갈다 맛있다 = 8



Local Representation 비교

	BoW	원-핫 인코딩	n-gram
공통 특징	국소 표현: 단어 혹은 단어의 집합에 하나의 숫자 를 할당하는 기법		
설명	단어에 자연수 를 할당하는 기법	단어에 이진수 를 할당하는 기법	연속된 단어의 집합 에 숫자를 할당하는 기법
장점	용량이 작음	이진수 표현은 컴퓨터 연산에 유리함 명목 인코딩에 유리함	간단한 문맥을 반영할 수 있음 간단한 수식 관계를 반영할 수 있음
단점	정보량이 적음	차원의 저주	용량이 큼 학습 시 많은 데이터를 요구함
공통 한계점	단어 간의 관계를 반영할 수 없음 다의어와 동음이의어를 구분할 수 없음		