

텍스트마이닝


: Distributed Representation

본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.


Distributed Representation

Word Embeddings: 단어를 숫자로 치환하는 것

- 컴퓨터는 기본적으로 숫자밖에 인식하지 못한다.
- 인간의 언어는 숫자가 아니므로, 컴퓨터에게 인간의 언어를 인식시키기 위해서는 인간의 언어를 숫자로 바꿔야 한다.
- 관건은 어떻게 바꿀 것인가?



Word Embeddings의 종류



• 단어를 벡터로 -> word2vec

• 문서를 벡터로-> doc2vec

• 단어를 음운으로 쪼개서 -> FastText

• 공동 등장 확률(동시출현확률)

Distributed Representation

Local Representation의 한계

- 단어 간 유사 관계를 반영하지 못함 (e.g., 밥 = 0, 물 = 1, 빵 = 2이라고 해서, 밥과 물이 밥과 빵의 관계보다 가깝지 않음)
- 다의어, 동음이의어를 구분하지 못함 (e.g., 사과(apple)와 사과(apology)를 구분하지 못함)

Distributed Representation: 하나의 단어를 하나의 행렬로 치환하는 것

- 가정 1. 단어의 의미는 주변 단어 분포로 이해될 수 있다.
- 가정 2. 단어 의미는 단어 벡터 안에 인코딩 될 수 있다.
- -> 목적?

Distributed Representation : Word2Vec


◆ Word2vec (Word to Vector):

단어 간의 관계를 통해 **단어**에 의미 행렬을 부여하는 방법론

처음에는 랜덤한 벡터값을 가지지만 학습하면서 주변 단어들과 비슷한 벡터로 변환된다.

CBOW


주위에 있는 단어들을 가지고 중간에 위치하는 하나의 단어를 예측한다.



CBOW

Skip-gram

중간에 위치하는 단어를 가지고 주위에 있는 단어를 예측한다.



Skip-gram



Distributed Representation : Word2Vec

◆ Word2vec (Word to Vector):

단어 간의 관계를 통해 **단어**에 의미 행렬을 부여하는 방법론

CBOW 는 주변 단어들을 입력으로 받아 중심 단어를 예측한다.

CBOW
주위에 있는 단어들을 가지고 중간에 위치하는
하나의 단어를 예측한다.




Distributed Representation : Word2Vec

◆ Word2vec (Word to Vector):

단어 간의 관계를 통해 **단어**에 의미 행렬을 부여하는 방법론

Skip-gram 는 중심 단어를 입력으로 받아 주위 단어를 예측한다.

Skip-gram
중간에 위치하는 단어를 가지고 주위에 있는 단어를
예측한다.



Skip-gram




My lovely **cat** sits on the table

My lovely **cat** sits on the table


- ✦ 말뭉치(=문서)가 커지거나, 저빈도 단어들이 있는 경우에 skip-gram의 성능이 더 높다고 알려져 있어, 통상적으로 skipgram을 사용한다.
- 왜? → 학습할 데이터의 수가 많아지기때문!

중심단어	주위단어
cat	My
cat	lovely
cat	sits
cat	on
sits	lovely
sits	cat
sits	on
sits	the

Distributed Representation : Word2Vec



Distributed Representation : Word2Vec



Distributed Representation : Doc2vec


◆ Doc2Vec (Document to Vector):

단어 간의 관계를 통해 **문서**에 의미 행렬을 부여하는 방법론

처음에는 랜덤한 벡터값을 가지지만 학습하면서 주변 단어들과 비슷한 벡터로 변환된다.


PV-DM

Paragraph ID Vector와 Word Vector를 이용해
다음 Word Vector를 예측하는 방법론



PV-DBOW

Paragraph ID Vector만 이용해
모든 Word Vector를 예측하는 방법론




Distributed Representation : Doc2vec

◆ Doc2Vec (Document to Vector):

단어 간의 관계를 통해 **문서**에 의미 행렬을 부여하는 방법론

PV-DM Paragraph ID vector 와 word vector를 통해 document vector 생성





Distributed Representation : Doc2vec

◆ Doc2Vec (Document to Vector):

단어 간의 관계를 통해 **문서**에 의미 행렬을 부여하는 방법론

PV-DBOW 단어 순서를 고려하지않고 문서 벡터를 사용해서 단어 를 예측 / 문서의 의미파악에 중점



Distributed Representation : PV-DM vs PV-DBOW

	PV-DM	PV-DBOW
INPUT	문서 벡터와 단어 벡터	문서 벡터만 사용
단어 순서 고려	단어 순서를 고려	단어 순서를 고려하지 않음
학습 속도	상대적으로 느림 (단어 순서와 주변 단어를 고려해야 하므로)	상대적으로 빠름 (단어 순서 고려 안 하므로 연산이 간단)
문맥 정보 반영	문맥 정보 반영됨	문맥 정보 반영 안 됨
장점	단어 순서와 문맥을 반영해 더 정교한 벡터 학습	더 빠른 학습 속도 메모리 요구 사항 적음
단점	더 느린 학습 속도 더 많은 메모리 소모	문맥 정보를 반영하지 못함 문서 벡터가 더 일반적임
사용 예시	문서의 구체적인 맥락을 고려해야 할 때	문서 내 단어들의 빈도나 주제에 대한 정보만 필요할 때 문서의 전반적인 의미가 주로 필요할 때

Distributed Representation : Fast Text

◆ Fast Text

단어 간의 관계를 통해 **음운에** 의미 행렬을 부여하는 방법론

word2vec: “king”은 계급 높은 남성을 의미해.

fast text: “king”은 “k” + “i” + “n” + “g” 이야.

장점

- 새로운 단어도 음운의 조합을 바탕으로 의미 유추 가능
- 어휘 사전의 최대 크기가 어휘의 개수가 아닌 음운의 개수로 정의되므로, 다른 distributed representation에 비해 용량이 작음

단점

- 학습한 단어 한정으로는 성능이 word2vec이나 doc2vec보다 떨어짐
- 음운의 조합으로 의미를 유추하기 때문에, 이상한 추론이 발생함
(e.g., boy와 boycott을 유사하게 볼 수 있음)

Distributed Representation : 비교

	Word2vec	Doc2vec	FastText	GloVe
공통 특징	분산 표현: 단어 혹은 단어의 집합에 의미 행렬 벡터 를 할당하는 기법 단어 간 관계를 반영할 수 있음			
설명	단어 에 의미 행렬 벡터를 할당하는 기법	단어 및 문장 에 의미 행렬 벡터를 할당하는 기법	음운(글자) 에 의미 행렬 벡터를 할당하는 기법	Window 밖의 관계까지 고려하여 단어에 의미 행렬 벡터 를 할당하는 기법
장점	가장 기본적인 분산 표현	문장이나 문단 단위의 분석 가능	학습하지 않은 단어의 의미를 유 추할 수 있음	단어 간 관계 도출에 강력함
단점	-	-	일반적으로 성능이 좋지 않음	용량이 큼
사용특징	- Word2vec : 단어간의 의미나 관계 분석이 중요할때 / 단어단위의 학습이 필요할때 - doc2vec: 문서나 문장 수준에서 벡터 생성 -> 문서나 문장 전체의 의미를 파악해야할때			