

텍스트마이닝

: LDA 토픽모델링


본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.

LDA (Latent Dirichlet Allocation)

◆ LDA 토픽모델링이란?

문서 안에서 주제를 찾아내는 기술

자동으로 비슷한 주제끼리 묶어주는 역할 (문서클러스터링)



(가정) 문서는 여러 개의 토픽으로 이루어질 것이며, 단어는 토픽 별로 분포할 것이다.

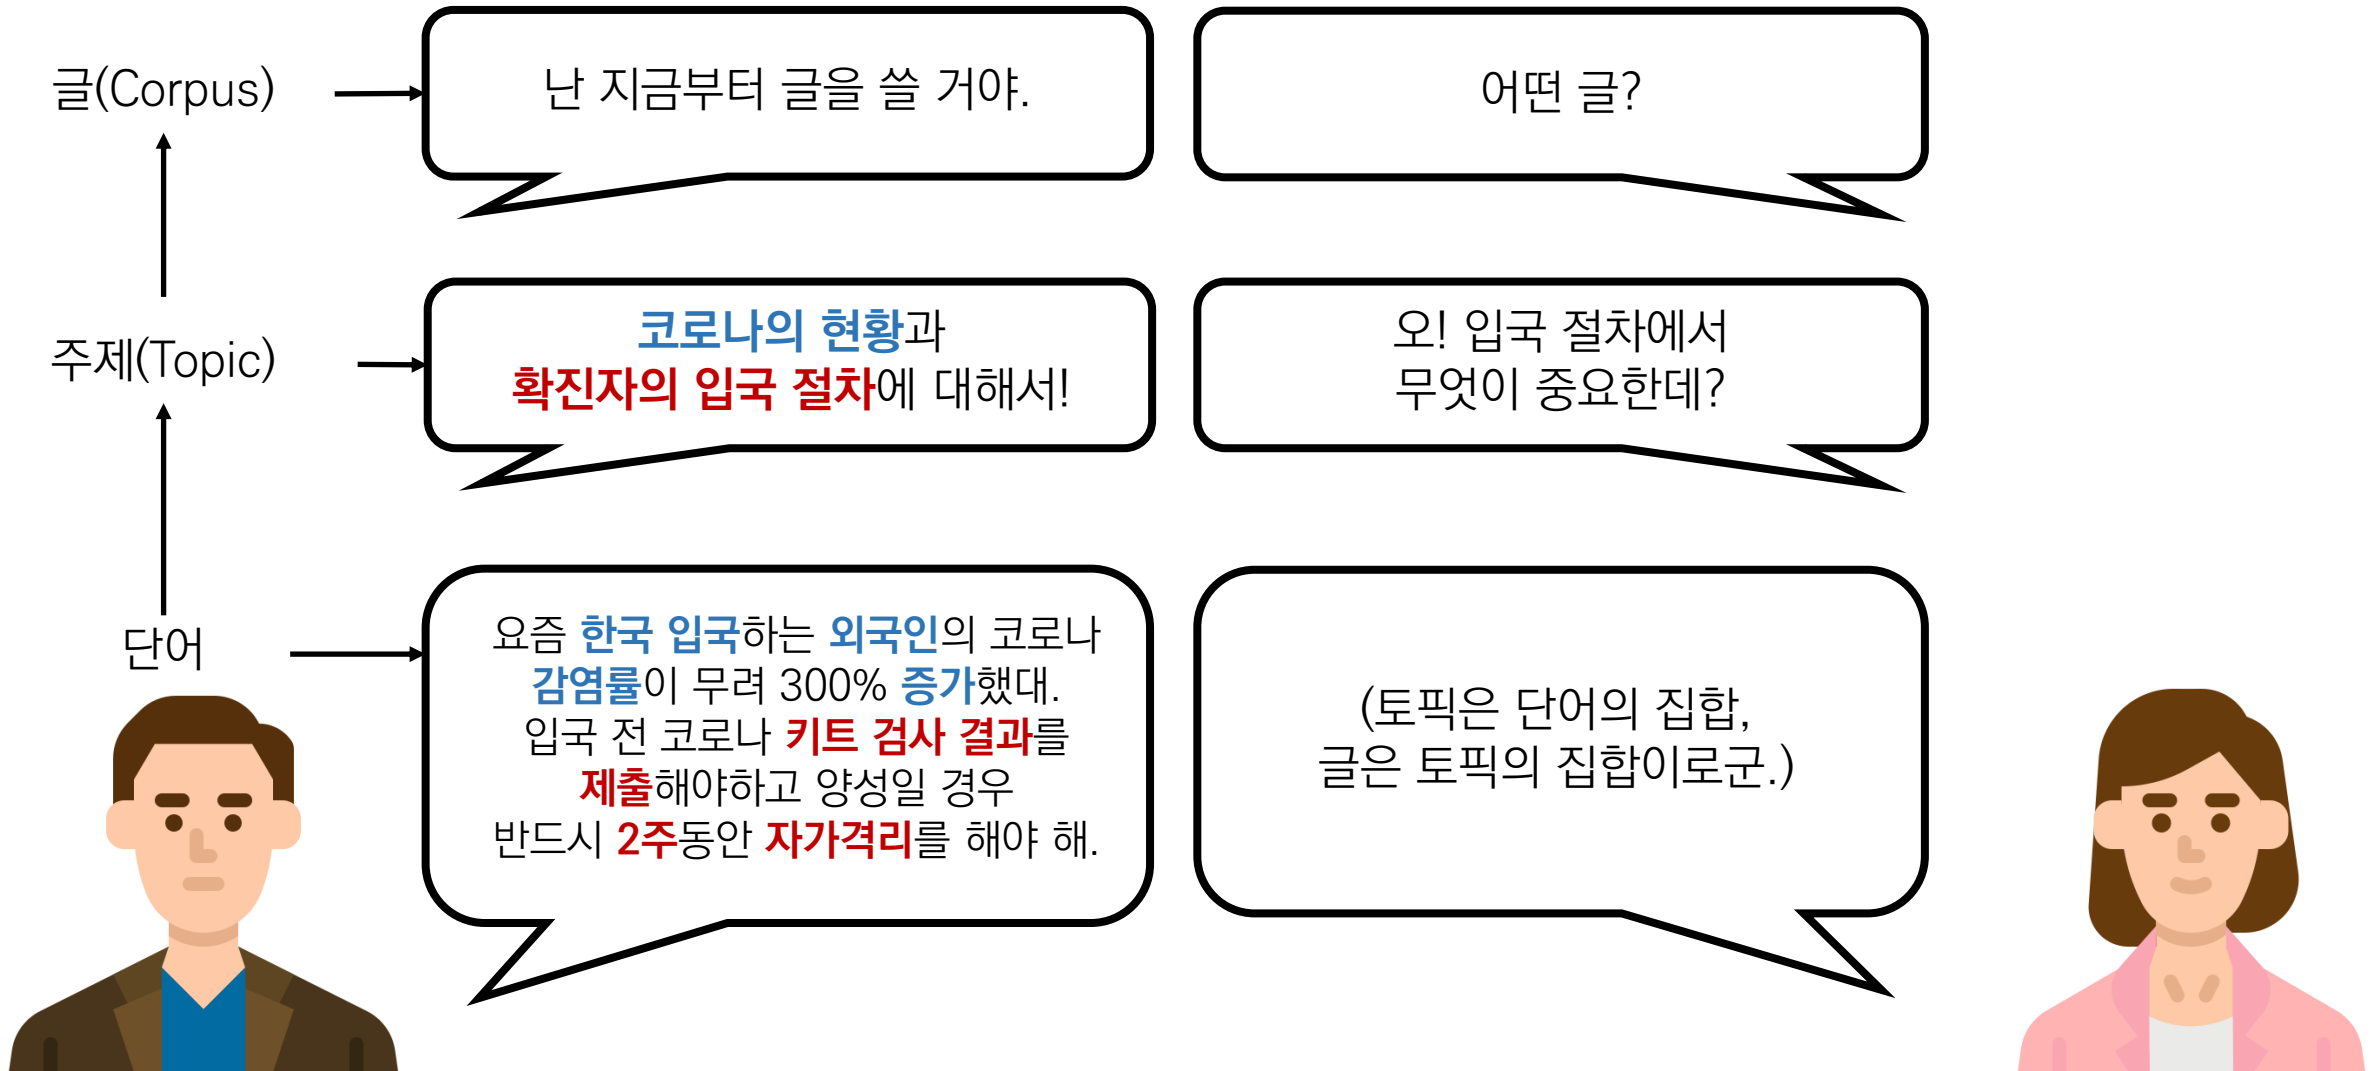
문서 → 여러 개의 토픽이 섞여있음

토픽 → 여러 단어로 이루어져 있음

예시) 문서1_스마트폰 리뷰에 관련된 문서1은

‘전자기기’에 관련된 토픽 70% / ‘소프트웨어’에 관련된 토픽 30%로 구성되어있다.

LDA (Latent Dirichlet Allocation)



TF-IDF VS LDA

TF - IDF

VS

LDA

목적

개별 단어(단어의 중요도)를 평가
각 단어가 문서에서 얼마나 중요한지를 수치화
벡터화 가능..!

출력

코로나 확진 격리 검사 백신

문서1	[0.3, 0.0, 0.4, 0.1, 0.2]
문서2	[0.0, 0.5, 0.2, 0.0, 0.3]
문서3	[0.2, 0.1, 0.0, 0.6, 0.0]

장점

계산 속도 빠름, 유사도 계산 가능

단점

문맥, 순서 반영 X
→ 의미적으로 비슷한 문서를 묶는 작업에 부적합
→ 주제를 직접적으로 알 수 없음

문서에서 잠재적인 주제 추출 (문서 클러스터링)
문서가 하나의 벡터가 아니라 토픽 확률 분포로 표현
가정 : 문서는 여러 개의 토픽으로 구성될 것이다.

토픽1 토픽2 토픽3

문서1	[0.3, 0.3, 0.4]
문서2	[0.3, 0.5, 0.2]
문서3	[0.8, 0.1, 0.1]

→ 토픽1 : 코로나 자가격리
토픽2 : 백신의 부작용
토픽3 : 코로나 검사

LDA를 사용하면 유사한 주제를 가진 문서 간의 비교 가능
같이 나오는 비슷한 단어들을 같은 토픽으로 묶어줌

계산량이 크고, 해석이 어려울 수 있음
→ 토픽 수를 미리 정해야함

LDA (Latent Dirichlet Allocation)

1) 사용자는 알고리즘에게 토픽의 개수 k 를 설정한다.

- LDA는 토픽의 개수 k 를 입력 받으면, k 개의 토픽이 M 개의 전체 문서에 걸쳐 분포되어 있다고 가정

2) 모든 단어를 k 개 중 하나의 토픽에 무작위로 할당한다.

- LDA는 모든 문서의 모든 단어에 대해서 k 개 중 하나의 토픽을 랜덤으로 할당
- 각 문서는 랜덤 토픽을 가지며, 토픽은 단어 분포를 가짐: 그러나 이 결과는 전부 틀린 상태

3) 각 문장이 어떤 토픽에 더 많이 포함되는지 확인한다. (반복적으로 작동)

- 같은 문서안에서, 특정 단어가 주로 어떤 토픽에 속하는지 보고, 다른 문서에서도 같은 단어가 어떤 토픽에 속했는지 비교한다.
- $p(\text{topic } t \mid \text{document } d)$: 문서 d 의 단어들 중 토픽 t 에 해당하는 단어들의 비율
- $p(\text{word } w \mid \text{topic } t)$: 단어 w 를 갖고 있는 모든 문서들 중 토픽 t 가 할당된 비율

LDA (Latent Dirichlet Allocation)

사용자는 알고리즘에게 토픽의 개수 k 를 설정한다.

- LDA는 토픽의 개수 k 를 입력 받으면, k 개의 토픽이 M 개의 전체 문서에 걸쳐 분포되어 있다고 가정


“페르시아 고양이는 귀엽다”

“대구 사과는 맛있다”

“고양이가 사과를 맛있게 먹는다”

토픽은 2개!

2개의 토픽이 3개의 문서에
걸쳐 분포되어 있겠군!



LDA (Latent Dirichlet Allocation)

모든 단어를 k개 중 하나의 토픽에 할당한다.

- LDA는 모든 문서의 모든 단어에 대해서 k개 중 하나의 토픽을 랜덤으로 할당
- 각 문서는 랜덤 토픽을 가지며, 토픽은 단어 분포를 가짐: 그러나 이 결과는 전부 틀린 상태

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”

“고양이” “사과”, “맛있-” “먹-”

일단 단어별로
랜덤 분배!

당연히 지금은
엉터리겠지!



LDA (Latent Dirichlet Allocation)

모든 문서의 모든 단어에 대해서 아래의 사항을 반복 진행한다. (iterative)

- $p(\text{topic } t \mid \text{document } d)$: 문서 d 의 단어들 중 토픽 t 에 해당하는 단어들의 비율

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”

“고양이” “사과”, “맛있-” “먹-”

1번 문장은 빨간색 토픽이 더 많으니까
“고양이”도 빨간색 토픽과 관련이 있나?

3번 문장은 빨간색과 파란색
토픽의 수가 같으니까
어느 쪽이라도 이상하지 않겠네.



LDA (Latent Dirichlet Allocation)

모든 문서의 모든 단어에 대해서 아래의 사항을 반복 진행한다. (iterative)

- $p(\text{word } w \mid \text{topic } t)$: 단어 w 를 갖고 있는 모든 문서들 중 토픽 t 가 할당된 비율

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”

“고양이” “사과”, “맛있-” “먹-”

엥 그런데 “고양이”는 1번 문장에선
파란색인데 3번 문장에선 빨간색이네

아까 “고양이”가 빨간 문장에 관련이 있을
수도 있다고 했으니까
“고양이”는 빨강으로 통일!



LDA (Latent Dirichlet Allocation)

모든 문서의 모든 단어에 대해서 아래의 사항을 반복 진행한다. (iterative)

- $p(\text{topic } t \mid \text{document } d)$: 문서 d 의 단어들 중 토픽 t 에 해당하는 단어들의 비율

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”

“고양이” “사과”, “맛있-” “먹-”

2번 문장은 **파란색 토픽**이 더 많으니까
“사과”도 **파란색 토픽**과 관련이 있나?

3번 문장은 빨간색과 파란색
토픽의 수가 같으니까 어느 쪽이라도
이상하지 않겠네.



LDA (Latent Dirichlet Allocation)

모든 문서의 모든 단어에 대해서 아래의 사항을 반복 진행한다. (iterative)

- $p(\text{word } w \mid \text{topic } t)$: 단어 w 를 갖고 있는 모든 문서들 중 토픽 t 가 할당된 비율

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”

“고양이” “사과”, “맛있-” “먹-”

엥 그런데 “사과”는 2번 문장에선
빨간색인데 3번 문장에선 파란색이네

아까 “사과”가 파란색 토픽과 관련이
있을 수도 있다고 했으니까
“사과”는 파란색 토픽으로 통일!



LDA (Latent Dirichlet Allocation)

모든 문서의 모든 단어에 대해서 아래의 사항을 반복 진행한다. (iterative)

- $p(\text{word } w \mid \text{topic } t)$: 단어 w 를 갖고 있는 모든 문서들 중 토픽 t 가 할당된 비율

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”

“고양이” “사과”, “맛있-” “먹-”

3번문장은 맛있-” 특정 토픽일 확률이 50%네
2번 문장에서 “맛있-”이
파란색 토픽일 확률이 100%이니까
3번 문장에서도 파란색이지 않을까?



LDA (Latent Dirichlet Allocation)

모든 문서의 모든 단어에 대해서 아래의 사항을 반복 진행한다. (iterative)


- $p(\text{topic } t \mid \text{document } d)$: 문서 d 의 단어들 중 토픽 t 에 해당하는 단어들의 비율

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-”


“고양이” “사과”, “맛있-” “먹-”

“먹-”은 모르겠는데 3번 문장이 75% 파란 색이니까 파란색 토픽으로 추정해야겠다.



LDA (Latent Dirichlet Allocation)

컴퓨터가 “수학적”으로 나눈 토픽이기 때문에, 각 토픽이 어떤 “의미적” 특징을 가지고 있는지 해석하는 것은 인간의 몫



고양이에 대한 이야기와
사과에 대한 이야기인가?

“페르시아”, “고양이”, “귀엽다”

“대구”, “사과”, “맛있-

“고양이” “사과”, “맛있-” “먹-

LDA (Latent Dirichlet Allocation)

◆ LDA 평가 지표

Perplexcity (다른 문서의 토픽을 얼마나 잘 예측하는가)

LDA에서 문서의 단어들이 **특정 토픽에서 생성될 확률**을 모델링
Perplexity는 이 확률값이 얼마나 신뢰할 수 있는지를 수치화

• Perplexity (혼란도) → "학생이 문제를 얼마나 잘 풀었는지"

Perplexity 예시

시험을 봤는데 정답률이 높으면 Perplexity가 낮아지고,
정답률이 낮으면 Perplexity가 높아짐

즉, Perplexity는 모델이 문서 데이터를 얼마나 잘 학습했는지
(확률적으로 맞추는지) 를 측정

Coherence (각 토픽이 얼마나 일관성 있는가)

토픽 안에 있는 단어들이 **서로 얼마나 관련이 있는지를 평가**
즉, 같은 토픽에 있는 단어들이 실제로 자주 같이 등장하는지 확인
일반적으로 "단어 간 유사도"로 확인

• Coherence (일관성) → "학생이 답을 얼마나 이해하기 쉽게 설명했는지"

Coherence 예시


학생이 답을 맞혔다고 해도, 엉뚱한 단어를 조합해서 설명하면 채점자가
이해하기 어렵다.

Coherence는 토픽이 사람이 봤을 때 의미 있게 구성되어 있는지를 평가함

LDA (Latent Dirichlet Allocation)


◆ LDA 평가 지표

Perplexcity (다른 문서의 토픽을 얼마나 잘 예측하는가)



- Perplexity값이 작으면 토픽모델이 문서를 잘 반영된다고 알 수 있음
- Perplexity는 낮을수록 좋으나 낮다고 해서, 결과가 해석 용이하다는 의미는 아님
- 모델이 생성한 토픽이 인간에게 얼마나 의미 있고 해석 가능한지를 반영하지 않기 때문
- 지나치게 낮은 Perplexity는 과적합(overfitting)의 가능성을 나타낼 수 있음

Coherence (각 토픽이 얼마나 일관성 있는가)



- Coherence는 모델이 생성한 토픽들의 주제 일치성을 평가하는 지표로 사용
- Coherence score가 높을 수록 의미론적 일관성이 높음
- 문서 집합의 Coherence가 높은게 무조건 좋다?
 - > 높은 coherence가 특정 주제에 국한될 수 있음 (너무 세부적이거나 제한된 정보 제공의 위험성)
 - > 과적합의 가능성 있음

LDA (Latent Dirichlet Allocation)

◆ LDA 평가 지표

Perplexity가 낮지만 Coherence가 낮은 경우 (안 좋은 모델)

- 토픽 1: ["카메라", "배터리", "속도", "화면", "디자인"]
- 토픽 2: ["이", "것", "좋아요", "하는", "사용"]
- 토픽 3: ["배터리", "빠르다", "크기", "좋음", "디자인"]

📌 문제점?

Perplexity는 낮아서 모델이 데이터를 잘 설명한다고 생각할 수 있지만

사람이 보기엔 토픽이 섞여 있어서 해석이 어렵다!

("이, 것, 하는" 같은 불필요한 단어 포함)

Perplexity는 높지만 Coherence가 높은 경우 (괜찮은 모델)

- 토픽 1: ["카메라", "화질", "사진", "촬영", "렌즈"]
- 토픽 2: ["배터리", "충전", "전원", "용량", "오래"]
- 토픽 3: ["디자인", "컬러", "세련", "고급", "스타일"]

📌 장점?

•Perplexity는 다소 높을 수 있지만...

•사람이 보기에는 토픽이 잘 나뉘어 있어서 의미가 분명하다!

→ Coherence가 높으면, 사람이 해석하기 좋은 모델!


→ 실제로 의미 있는 토픽을 얻을 수 있음.

LDA (Latent Dirichlet Allocation)

▶ Elbow point

- 최적의 클러스터 수(K)를 결정하기 위해 사용하는 개념
- 그래프가 급격히 변하는 지점을 의미하며, 이 지점이 최적의 클러스터 수
- 이 지점 이후로 클러스터 수를 추가해도 감소폭이 줄어드는 경향이 있어, 모델의 성능 향상에 미치는 영향이 적어짐
- 클러스터 수를 과도하게 늘리지 않고 데이터의 구조를 잘 반영할 수 있는 적절한 클러스터 수를 선택하는데 도움을 줄 수 있다..

Perplexcity
(다른 문서의 토픽을 얼마나 잘 예측하는가)



Coherence
(각 토픽이 얼마나 일관성 있는가)

